Institución Universitaria
Reacreditada en Alta Calidad

ANÁLISIS EXPLORATORIO Y LIMPIEZA DE DATOS

PROGRAMACIÓN AVANZADA
170304004

www.itm.edu.co

Vigilado Mineducación

HERRAMIENTAS DE VISUALIZACIÓN DE DATOS

En general, los datos están en todas partes: negocios, ciencia, salud, deportes. El reto de la ciencia de datos es entenderlos y explicarlos de forma clara.

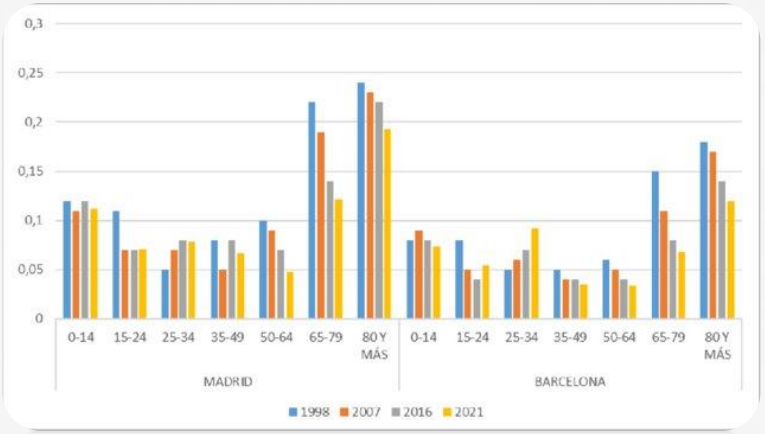
Vigilada Mineducación

HERRAMIENTAS DE VISUALIZACIÓN DE DATOS

En general, los datos están en todas partes: negocios, ciencia, salud, deportes. El reto de la ciencia de datos es entenderlos y explicarlos de forma clara.

Las herramientas de visualización y análisis ayudan a transformar tablas en historias con sentido, algunas de las principales son:

- Medidas estadísticas
- Histogramas
- Diagramas de dispersión (scatter plots)



https://www.researchgate.net/publication/373745673_cambiante_localizacion_de_la_poblacion_mayor_en_las_areas_metropolitanas_de_Barcelona_y_Madrid_Analisis_comparativo_de_tendencias_espaciales

Digilada Mineducación

- **Medidas estadísticas**

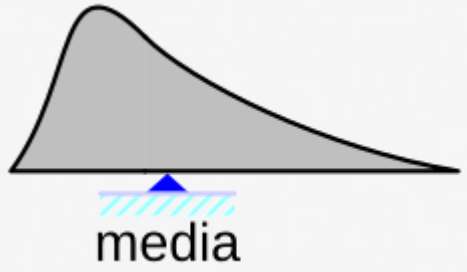
Las medidas estadísticas son valores que resumen y describen las características principales de un conjunto de datos. Ayudan a entender la información de manera rápida y sencilla.

Se dividen principalmente en dos categorías:

- Medidas de tendencia central
- Medidas de dispersión

Vigilada Mineducación

- **Medidas estadísticas**
  - Medidas de tendencia central



Media:

Es el promedio de los datos. Es ideal para datos numéricos sin valores extremos (atípicos), ya que estos distorsionan el resultado.

Mediana:

Es el **valor que se encuentra justo en el medio** de un conjunto de datos ordenado. No se ve afectada por los valores atípicos.



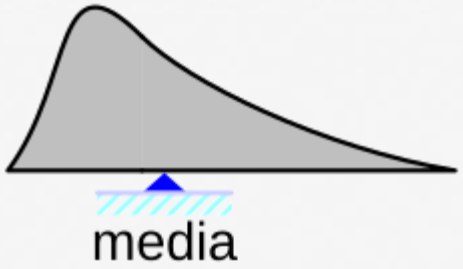
Moda:

Es el **valor que más se repite** en el conjunto de datos.



Vigilada Mineducación

- **Medidas estadísticas**
  - Medidas de dispersión (o variabilidad)



Rango:

Es la diferencia entre el **valor máximo y el valor mínimo**.

Varianza (s^2)

Mide qué tan lejos está cada valor del promedio. Una varianza alta significa que los datos están muy dispersos.

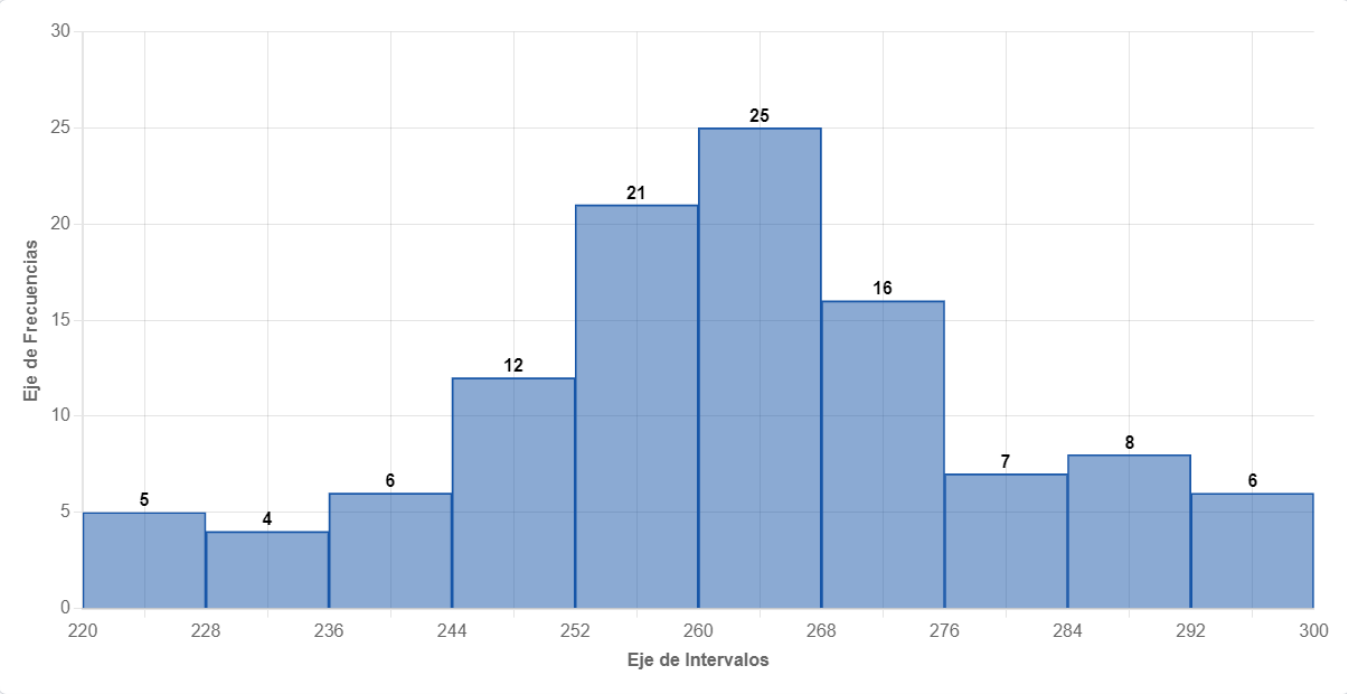
Desviación Estándar ($s = \sqrt{s^2}$)

Una desviación estándar baja indica que los datos tienden a estar cerca de la media, mientras que un valor alto indica que los datos están más dispersos.

Vigilada Mineducación

- **Histogramas**

Un histograma es un gráfico de barras que visualiza la distribución de frecuencia de un conjunto de datos numéricos continuos. Ayuda a entender la forma, el centro y la dispersión de los datos.

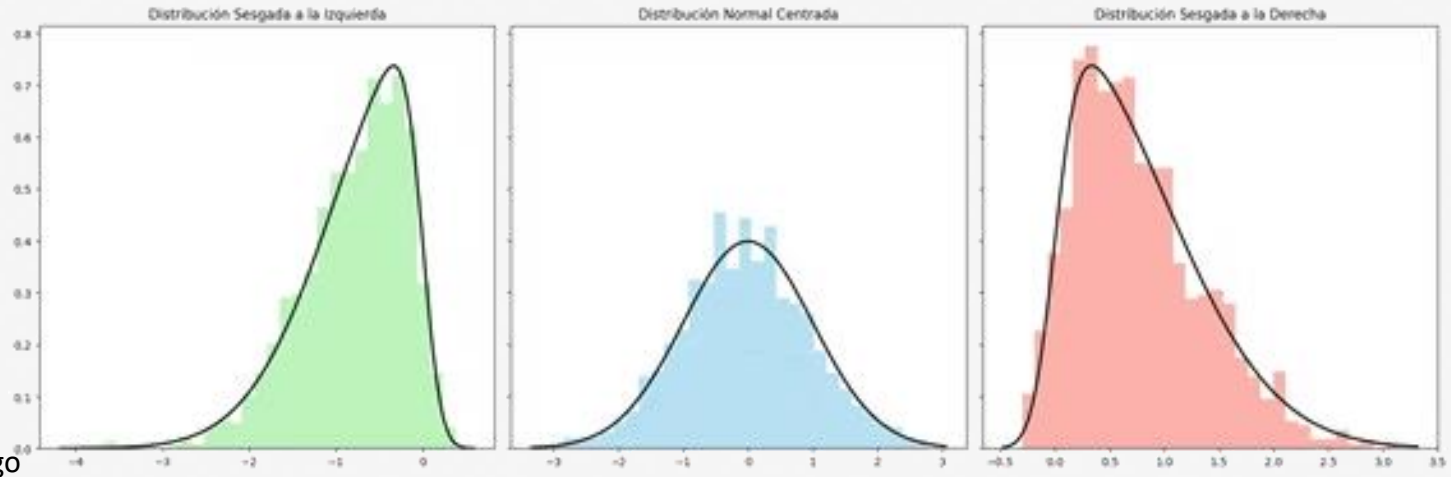


Vigilada Mineducación

- **Histogramas**

Los histogramas permiten identificar:

- **La forma de la distribución**: Si es simétrica (como una campana), sesgada (cola larga) a la derecha o sesgada a la izquierda.
- **Valores atípicos (outliers)**: Barras aisladas y lejanas del resto.
- **Concentración de los datos**: Dónde se agrupan la mayoría de los valores.



https://www.chreinvent.com/recursos/sesgo

Vigilada Mineducación

- **Diagramas de dispersión (Scatter Plots)**

Son gráficos que se utiliza para visualizar la relación entre dos variables numéricas.

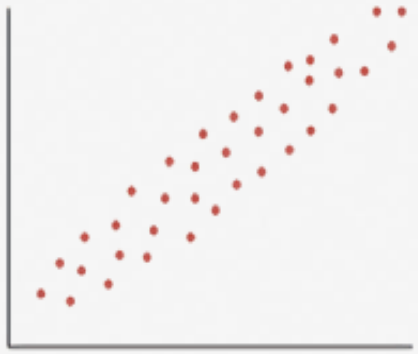
Cada punto en el gráfico representa una observación en los datos, con su posición determinada por los valores de las dos variables (una en el eje X y otra en el eje Y).

Vigilada Mineducación

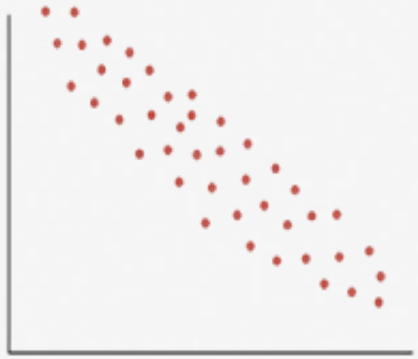
- **Diagramas de dispersión (Scatter Plots)**

Los Diagramas de dispersión permiten identificar:

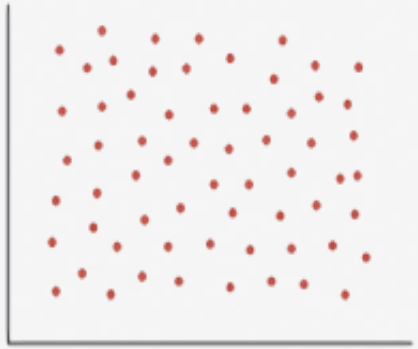
- **Correlación**: Es su principal utilidad, ya que dice cómo se comporta una variable cuando la otra cambia. Puede clasificarse como **Correlación Positiva, Correlación Negativa o Sin Correlación**



3. Correlación lineal positiva alta



5. Correlación lineal negativa alta



1. No hay correlación



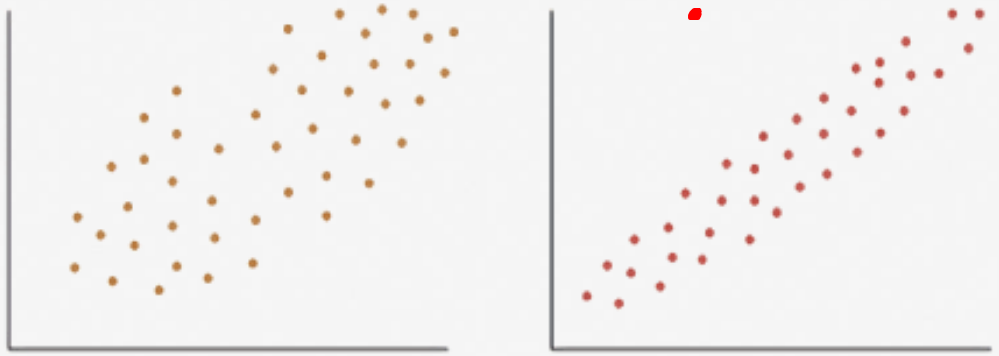
6. No hay correlación lineal

Vigilada Mineducación

- **Diagramas de dispersión (Scatter Plots)**

Los Diagramas de dispersión permiten identificar:

Fuerza de la relación: Si los puntos están muy agrupados formando una línea clara, la relación es fuerte. Si están muy dispersos, es débil.



2. Correlación lineal positiva

3. Correlación lineal positiva alta

Identificación de outliers : Puntos que se alejan del patrón general del resto de los datos.

Vigilada Mineducación

LIMPIEZA DE DATOS

Limpiar datos, "data cleaning" o depuración de datos, es el proceso de identificar, corregir o eliminar errores, inconsistencias e imprecisiones en un conjunto de datos.

El objetivo es asegurar que los datos sean precisos, completos y consistentes, lo que resulta en información de alta calidad.



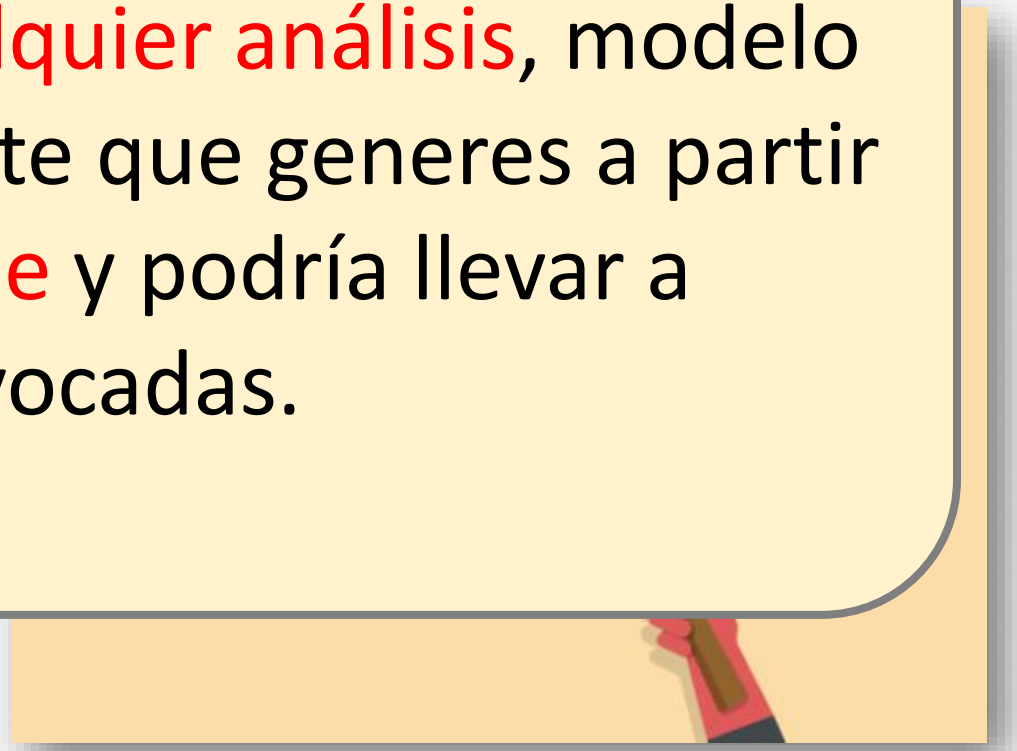
Vigilada Mineducación

https://it-nova.co/6-errores-comunes-en-la-limpieza-de-datos

LIMPIEZA DE DATOS

Limpiar datos, “data cleaning” o depuración de datos, es el proceso de
ir
E
d
c
ir

Si los datos están “sucios”, cualquier análisis, modelo de inteligencia artificial o reporte que generes a partir de ellos será poco confiable y podría llevar a decisiones equivocadas.



Vigilada Mineducación

¿POR QUÉ ES IMPORTANTE LIMPIAR LOS DATOS?

La limpieza de datos es un paso fundamental en cualquier proyecto que involucre análisis de datos, ciencia de datos o aprendizaje automático (*machine learning*).



Vigilada Mineducación

https://guias.donweb.com/limpieza-de-base-de-datos-con-wp-sweep

¿POR QUÉ ES IMPORTANTE LIMPIAR LOS DATOS?

- **Mejora la precisión de los análisis:** Decisiones basadas en datos limpios y de alta calidad son mucho más acertadas.



https://es.vecteezy.com/arte-vectorial/5187421-contorno-plano-concepto-icono-de-datos-limpieza-eliminar-datos-inexactos

Vigilada Mineducación

¿POR QUÉ ES IMPORTANTE LIMPIAR LOS DATOS?

- **Mejora la precisión de los análisis:** Decisiones basadas en datos limpios y de alta calidad son mucho más acertadas.
- **Aumenta la eficiencia:** Los científicos de datos dedican menos tiempo a lidiar con errores y más tiempo a extraer información.



Vigilada Mineducación

https://es.vecteezy.com/arte-vectorial/5187421-contorno-plano-concepto-icono-de-datos-limpieza-eliminar-datos-inexactos

¿POR QUÉ ES IMPORTANTE LIMPIAR LOS DATOS?

- **Mejora la precisión de los análisis:** Decisiones basadas en datos limpios y de alta calidad son mucho más acertadas.
- **Aumenta la eficiencia:** Los científicos de datos dedican menos tiempo a lidiar con errores y más tiempo a extraer información.
- **Resultados confiables en modelos de IA:** Los algoritmos de aprendizaje automático son tan buenos como los datos con los que se entrenan. Datos sucios generan modelos imp y sesgados.



Vigilada Mineducación

https://es.vecteezy.com/arte-vectorial/5187421-contorno-plano-concepto-icono-de-datos-limpieza-eliminar-datos-inexactos

LIMPIEZA DE DATOS



El proceso de limpieza se enfoca en detectar y solucionar varios tipos de problemas.

PROBLEMA	DESCRIPCIÓN	EJEMPLO
Datos duplicados	Registros idénticos o casi idénticos que aparecen más de una vez.	Tener registrado a "Juan Pérez" y a "Juan Perez" (sin tilde) como dos personas distintas.
Valores faltantes	Campos vacíos o nulos en el conjunto de datos.	Una encuesta donde un participante no respondió su edad.
Datos incorrectos o inexactos	Información que no es correcta o no tiene sentido en el contexto.	Un cliente con una edad registrada de "200 años".
Inconsistencias de formato	Datos que deberían ser uniformes pero se presentan de diferentes maneras.	Fechas registradas como "10/05/2023", "10-May-2023" y "2023/05/10" en la misma columna.
Valores atípicos (*Outliers*)	Puntos de datos que son significativamente diferentes del resto.	En un registro de salarios de una empresa, encontrar un valor de $10 por mes para un analista.
Datos irrelevantes	Columnas o filas que no aportan valor al análisis que se quiere realizar.	En un análisis de ventas, tener una columna con el color de ojos del vendedor.

"https://www.flaticon.es/iconos-gratis/limpieza-de-datos" title="limpieza de datos iconos">Limpieza de datos iconos creados por Freepik - Flaticon

Pasos habituales en el proceso de limpieza

Aunque las herramientas y técnicas pueden variar, el proceso general de limpieza de datos suele seguir una secuencia lógica:

1) **Inspección y perfilado:** El primer paso es explorar los datos para entender su estructura, calidad y encontrar las anomalías mencionadas anteriormente.

Vigilada Mineducación

Pasos habituales en el proceso de limpieza

Aunque las herramientas y técnicas pueden variar, el proceso general de limpieza de datos suele seguir una secuencia lógica:

1) **Inspección y perfilado:** El primer paso es explorar los datos para entender su estructura, calidad y encontrar las anomalías mencionadas anteriormente.
2) **Eliminación de duplicados:** Se identifican y eliminan los registros repetidos.

Vigilada Mineducación

Pasos habituales en el proceso de limpieza

Aunque las herramientas y técnicas pueden variar, el proceso general de limpieza de datos suele seguir una secuencia lógica:

1) **Inspección y perfilado:** El primer paso es explorar los datos para entender su estructura, calidad y encontrar las anomalías mencionadas anteriormente.
2) **Eliminación de duplicados:** Se identifican y eliminan los registros repetidos.
3) **Manejo de valores faltantes:** Se decide una estrategia para los datos ausentes. Las opciones comunes incluyen eliminar la fila completa, **imputar** (estimar) el valor basándose en otros datos (como la media o la mediana), o usar un algoritmo avanzado.

Vigilada Mineducación

Pasos habituales en el proceso de limpieza

Aunque las herramientas y técnicas pueden variar, el proceso general de limpieza de datos suele seguir una secuencia lógica:

4) **Corrección de errores estructurales:** Se estandarizan los formatos (fechas, números, texto), se corrigen errores tipográficos y se asegura la consistencia en las categorías.
   - Se recomienda convertir variables categóricas a un formato numérico porque la gran mayoría de los algoritmos de machine learning y modelos estadísticos no pueden procesar texto o etiquetas directamente.

Vigilada Mineducación

Pasos habituales en el proceso de limpieza

Aunque las herramientas y técnicas pueden variar, el proceso general de limpieza de datos suele seguir una secuencia lógica:

5) **Tratamiento de valores atípicos:** Se analizan los valores extremos para determinar si son errores o datos genuinos y se decide si deben eliminarse o ajustarse.

Vigilada Mineducación

Pasos habituales en el proceso de limpieza

Aunque las herramientas y técnicas pueden variar, el proceso general de limpieza de datos suele seguir una secuencia lógica:

5) **Tratamiento de valores atípicos:** Se analizan los valores extremos para determinar si son errores o datos genuinos y se decide si deben eliminarse o ajustarse.

6) **Validación:** Una vez completada la limpieza, se realiza una última revisión para confirmar que los datos son consistentes y están listos para ser analizados.

Vigilada Mineducación

EJEMPLO DE LIMPIEZA DE DATOS

1) Inspección y perfilado:

Antes de cambiar nada, necesitas entender tus datos. Un buen primer paso es cargar el archivo y usar tres funciones esenciales:

- **df**, **df.head()**, **df.tail()** para ver las primeras/últimas filas.
- **df.info()** para ver el tipo de dato de cada columna y cuántos valores no nulos hay.
- **df.isnull().sum()** para contar el total de valores faltantes por columna.
- **df.duplicated().sum()** para contar los registros duplicados

Vigilada Mineducación

EJEMPLO DE LIMPIEZA DE DATOS

2) Eliminación de duplicados:

Elimina las filas duplicadas de tu DataFrame usando el comando

- **df.drop_duplicates(inplace=True)**

Vigilada Mineducación

EJEMPLO DE LIMPIEZA DE DATOS

3) Manejo de valores faltantes:

Una primera opción es eliminar cualquier fila que tenga valores faltantes.

- **df = df.dropna()**

En algunos casos no es buena idea eliminar las filas con valores faltantes, porque se perdería mucha información.

Vigilada Mineducación

EJEMPLO DE LIMPIEZA DE DATOS

3) Manejo de valores faltantes:

Otra solución consiste en "Imputar" los valores faltantes. Una estrategia simple y efectiva es rellenar los vacíos con la mediana o la media. Por ejemplo, supongamos que 'Columna' tiene datos faltantes y se van a "completar" usando el promedio:

- **promedio = df['Columna'].mean()**
- **df.loc[df['Columna'].isnull(), 'Columna'] = promedio**

Vigilada Mineducación

EJEMPLO DE LIMPIEZA DE DATOS

3) Manejo de valores faltantes:

Otra solución consiste en "Imputar" los valores faltantes. Una estrategia simple y efectiva es rellenar los vacíos con la mediana o la media. Por ejemplo, supongamos que 'Columna' tiene datos faltantes y se van a "completar" usando el promedio:

- **promedio = df['Columna'].mean()**
- **df.loc[df['Columna'].isnull(), 'Columna'] = promedio**

CUIDADO: Imputar puede afectar la distribución de los datos.

Vigilada Mineducación

EJEMPLO DE LIMPIEZA DE DATOS

4) Corrección de errores estructurales: Eliminando columnas no útiles:

Algunas columnas son muy difíciles rellenar de forma precisa, lo más práctico es eliminarla por completo.

- **df.drop(['Columna1','Columna2','Columna3'],axis=1,inplace=True)**

Vigilada Mineducación

EJEMPLO DE LIMPIEZA DE DATOS

4) Corrección de errores estructurales: Conversión de Variables Categóricas a Numéricas:

Los modelos de machine learning necesitan números, no texto. Por ejemplo, es común encontrar columnas como Sex es una categoría binaria (male/female). Si este es el caso, se puede convertir fácilmente a números, por ejemplo: male = 0 y female = 1.

- **df['Sex'] = df['Sex'].map({'male': 0, 'female' : 1})**

Vigilada Mineducación

EJEMPLO DE LIMPIEZA DE DATOS

4) Corrección de errores estructurales: Conversión de Variables Categóricas a Numéricas:

En otros casos, hay datos distribuidos en algunas pocas categorías (‘A’, ‘B', ‘C'). La mejor técnica aquí puede ser crear una nueva columna para cada puerto (Cat_A, Cat_B, Cat_C) con valores de True o False, conocido como One-Hot-Encoding.

- **df = pd.get_dummies(df, columns=[‘Columna'], prefix='Cat’)**

- **df = pd.get_dummies(df, columns=[‘Columna'], prefix='Cat’, drop_first=True)**

Vigilada Mineducación

EJEMPLO DE LIMPIEZA DE DATOS

4) Corrección de errores estructurales: Corrección de registros casi idénticos

Supongamos que tuviéramos errores ortográficos, como una palabra escrita de varias formas: 'Electrónica', 'Electronica', 'electrónica' en la columna 'Area':

- **df['Area '].unique()**
- **df['Area'] = df['Area'].replace({'electronica': 'Electrónica', 'Electronica': 'Electrónica'})**

Esta es una solución "básica", existen estrategias más completas para hacer este tipo de limpieza.

Vigilada Mineducación

EJEMPLO DE LIMPIEZA DE DATOS

5) Tratamiento de valores atípicos

Este dataset no tiene este problema, pero supongamos que tuviéramos una edad ('Age') reportada de 200 años.

Podríamos filtrar las edades en un rango realista de 0 a 120 años:

- **df[(df['Age'] > 0) & (df['Age'] < 120)]**

Otra opción es no eliminar el dato, sino atípico, sino imputarlo:

- **valid_mean = df.loc[(df['Age'] > 0) & (df['Age'] < 120), 'Age'].mean()**
- **df.loc[(df['Age']<=0) | (df['Age']>=120), 'Age'] = valid_mean**

Vigilada Mineducación

EJEMPLO DE LIMPIEZA DE DATOS

6) Validación

Volver a usar los comandos que se hicieron en el primer paso

- **df.head()**
- **df.info()**
- **df.isnull().sum()**

Los resultados pueden guardarse en un nuevo archivo para no tener que realizar este proceso nuevamente.

Vigilada Mineducación



Institución Universitaria
Reacreditada en Alta Calidad

¡MUCHAS GRACIAS!

Material de apoyo usado para las clases de Programación Avanzada

Elaborado por:
Esteban Gonzalez Valencia
estebangonzalez@itm.edu.co

Hacia una era de Universidad y Humanidad